

DAY 3 . โปรเจกต์ลงมือทำ

Project 1: Data Cleaning

เริ่มเลย →

> toolkit

เครื่องมือวันนี้: Notebook + GitHub



Jupyter / Colab Notebook

- ✓ เขียนโค้ด + เห็นผลทีละ cell
- ✓ สลับ markdown (อธิบาย) กับ code (ทำ)
- ✓ อ่านจากบนลงล่างได้ทั้งกระบวนการ
- ✓ เครื่องมือมาตรฐานของงานวิเคราะห์



GitHub

- ✓ เก็บงาน + เก็บเวอร์ชัน (version control)
- ✓ commit เป็นระยะ ทำให้ประวัติเล่าเรื่องได้
- ✓ notebook เปิดดูบนเว็บได้เลย
- ✓ ลิงก์เดียวโชว์ recruiter ได้ทันที

หลักเดิมจากคาบ 1: ให้ AI เขียนโค้ดในแต่ละ cell ให้ได้ หน้าที่เราคือ "อ่านให้เข้าใจ + ตรวจสอบ" (คิด · สั่ง · ตรวจสอบ)

> notebook_anatomy

โน้ตบุ๊กที่ดี = เล่าเรื่องได้

สลับ markdown (อธิบาย) แล้ว code (ลงมือ) แล้ว output (ผล) ไปเรื่อย ๆ ให้คนอ่านตามได้

M ## Step 3: แปลง 0 เป็นค่าหาย

```
In [4]: df[cols] = df[cols].replace(0, np.nan)
```

→ Insulin 374 · SkinThickness 227 หาย

M ทำไม: 0 ในค่าการแพทย์ เป็นไปไม่ได้

...วนแบบนี้ทุกชั้น

Markdown cell

อธิบายว่า "กำลังทำอะไร ทำไม" หัวข้อ + เหตุผล

Code cell

โค้ด pandas ที่ลงมือทำจริง (ให้ AI เขียนได้)

Output

ผลลัพธ์ที่เรา "ตรวจ" เห็นที่ถูกต้องไหม

> project_setup

วางโครงโปรเจกต์ + สร้าง repo

โครงโฟลเดอร์

```
diabetes-cleaning/  
├── data/  
│   ├── raw/diabetes.csv  
│   └── clean/diabetes_clean.csv  
├── notebooks/  
│   └── cleaning.ipynb  
├── README.md  
└── .gitignore
```

terminal

```
$ git init  
$ git add .  
$ git commit -m "init: structure"
```

เคล็ดลับ: commit เป็นระยะหลังแต่ละขั้น ประวัติ git จะ "เล่าเรื่อง" การล้างข้อมูลของเรา

> the_dataset

ชุดข้อมูลสุขภาพจริง: Diabetes (Kaggle)

ข้อมูลผู้ป่วย 768 คน สำหรับทำนายเบาหวาน (Pima Indians Diabetes จาก Kaggle)

Glucose	BloodPr	SkinTh	Insulin	BMI	Age	Outcome
148	72	35	0	33.6	50	1
85	66	29	0	26.6	31	0
183	64	0	0	23.3	32	1
89	66	23	94	28.1	21	0
137	40	35	168	43.1	33	1

ค่าหายซ่อนอยู่

Insulin 374 · SkinTh 227
(เป็น 0)

0 ที่เป็นไปไม่ได้

BloodPr · BMI · Glucose
= 0

ดูสะอาดแต่หลอก ตา

isna() นอก 0 ค่าหาย

ค่าโดด

Insulin สูงถึง 846

ไม่มีซ้ำ

0 แลว ต้องตรวจ ไม่ใช่เดา

แผนล้างข้อมูล 6 ขั้น (ทำในโน้ตบุ๊ก)



1 · สืบค้นก่อน

หาปัญหาที่ซ่อนอยู่



2 · ลบแถวซ้ำ

+ ตัดที่ไม่เกี่ยว



3 · แปลง 0 ที่ผิด

0 = ค่าหายที่ซ่อน



4 · จัดการค่าโดด

outlier จริง vs ผิด



5 · จัดการค่าหาย

เติม / flag



6 · ตรวจสอบ + บันทึก

validate แล้ว save + push

ทุกขั้นทำแบบเดิม: สั่ง AI เขียน cell ให้ แล้วเรา "อ่านเข้าใจ + ตรวจสอบ output" แล้ว commit แล้วไปขั้นต่อไป

> setup_cell

0

เริ่มโน้ตบุ๊ก: import + โหลดข้อมูล

In [1]:

```
import pandas as pd
df = pd.read_csv(
    'data/raw/diabetes.csv')
df.shape

→ (768, 9)
```



อ่าน + ตรวจสอบ

- pandas = เครื่องมือหลักจัดการตาราง
- df = ตารางข้อมูลของเรา (DataFrame)
- .shape บอกขนาด ตรวจสอบ 768 แถว 9 คอลัมน์

> step_1_explore

1

สำรวจก่อน: หาปัญหาที่ซ่อนอยู่

In [2]:

```
df.info()
df.isna().sum()    # 0 ทุกคอลัมน์?!
df.describe()      # แต่ min = 0
```

→ `isna = 0` (ดูเหมือนสะอาด)

→ แต่ `Glucose/BP/BMI min = 0`



อ่าน + ตรวจสอบ

- `isna()` บอกไม่มีค่าหาย แต่ลอคตา
- `describe()` เผย `min = 0` ในค่าการแพทย์
- 0 ใน `BloodPressure/BMI` เป็นไปไม่ได้จริง
- จดจำนวนแถวเริ่มต้น 768 ไว้

> step_2_duplicates

2

ลบแถวซ้ำ

In [3]:

```
df.duplicated().sum()
```

→ 0

```
df = df.drop_duplicates()
```



อ่าน + ตรวจสอบ

- duplicated() หาแถวซ้ำ · drop_duplicates() ลบ
- 0 = ไม่มีซ้ำ = ผลลัพธ์ที่ถูกต้อง
- ต้อง "ตรวจสอบ" เอง ไม่ใช่ "เดา" ว่ามี/ไม่มี

> step_3_zeros

3

แปลง 0 ที่เป็นไปได้เป็นค่าหาย

In [4]:

```
import numpy as np
cols = ['Glucose', 'BloodPressure',
        'SkinThickness', 'Insulin', 'BMI']
df[cols] = df[cols].replace(0, np.nan)
df.isna().sum()
→ Insulin 374 · SkinThickness 227
```



อ่าน + ตรวจสอบ

- 0 ในค่าการแพทย์เหล่านี้ เป็นไปไม่ได้
- `replace(0, NaN)` เปิดเผยค่าหายที่ซ่อน
- ตอนนี้ค่าหายโผล่มาให้จัดการต่อได้

> step_4_outliers

4

จัดการค่าโดด (Outliers)

In [5]:

```
df[['Insulin', 'BMI']].describe()
```

→ Insulin max 846 • BMI max 67

```
df[df['Insulin'] > 600]
```

สืบก่อน: error หรือเคสจริง?



✓ อ่าน + ตัดสินใจ

- Insulin 846, BMI 67 สูงผิดปกติ
- ลบเพราะ "ผิด" ไม่ใช่เพราะ "โดด"
- จดเหตุผลที่ตัด/เก็บ ลงใน markdown


> step_5_missing

5

จัดการค่าหาย (Missing)

In [6]:

```
df['Insulin_missing'] = (  
    df['Insulin'].isna().astype(int))  
grp = df.groupby('Outcome')  
for c in ['Glucose', 'BloodPressure', 'BMI']:  
    df[c] = grp[c].transform(  
        lambda x: x.fillna(x.median()))
```



✓ อ่าน + ตัดสินใจ

- Insulin หาย 49% → ทำ flag แทนการเดิม
- ที่เหลือเดิม median แยกกลุ่มป่วย/ไม่ป่วย
- เดิม = การเอา จดวิธี + จำนวนจุด

> step_6_validate

6

ตรวจสอบผลรวม (Validate)

In [7]:

```
df.isna().sum()  
(df[cols] == 0).sum()  
→ ไม่มี 0 ที่เป็นไปไม่ได้แล้ว
```

```
df.shape  
df.describe()
```



เช็คลิสต์สุดท้าย

- ค่าหายจัดการครบ (เติม หรือ flag)
- ไม่มี 0 ที่เป็นไปไม่ได้เหลือแล้ว
- ช่วงค่าสมเหตุผลทางการแพทย์

> document_save

จัด markdown + บันทึกไฟล์

Markdown cell

สรุปการล้างข้อมูล

- Duplicates: 0 (ตรวจแล้วไม่มี)
- แปลง 0 เป็น NaN ใน 5 คอลัมน์การแพทย์
- Insulin: หาย 49% ทำ flag แทนเดิม
- Glucose/BP/BMI: เติม median by Outcome

In [8]:

```
df.to_csv(  
    'data/clean/diabetes_clean.csv',  
    index=False)
```



ทำไมสำคัญ (portfolio)

- markdown เล่า "การตัดสินใจ" ไม่ใช่แค่โค้ด
- แยก raw / clean ไม่ทับข้อมูลดิบ
- index=False กัน column เกินตอนเซฟ
- ใครเปิดอ่านก็เข้าใจทั้งกระบวนการ
- นี่คือการที่แยกงานมือใหม่กับมืออาชีพ

> commit_push

ขั้น GitHub: เก็บงาน + โช่วผลงาน

terminal

```
# .gitignore: กันไฟล์ที่ไม่ต้องเก็บ  
echo ".ipynb_checkpoints/" > .gitignore
```

```
$ git add .  
$ git commit -m "clean: zeros to  
    NaN, flag, impute missing"  
$ git push
```

ไม่แน่ใจ? ถาม Claude Code ช่วย push ได้

✓ ควรมีใน repo

- notebooks/cleaning.ipynb
- data/raw/diabetes.csv
- data/clean/diabetes_clean.csv
- README.md
- .gitignore

> portfolio_ready

ทำ repo ให้ "ปัง" ใน Portfolio



README ที่เล่าเรื่อง

ปัญหา · ข้อมูลรกยังง · แก้อยังง · ผลลัพธ์



notebook เปิดดูบนเว็บได้

GitHub เรนเดอร์ .ipynb ให้เลย (หรือใช้ nbviewer)



โชว์ before / after

ตาราง/ตัวเลขเทียบ ให้เห็นว่าสะอาดขึ้นจริง



อธิบายการตัดสินใจ

ทำไมแปลง 0 ทำไม flag Insulin (คิดเป็น)

> watch_out

ระวัง! กับดักตอนล้างข้อมูล



ล้างมากเกินไป (over-clean)

ลบ outlier ที่จริง ๆ เป็นของจริง = ทำข้อมูลบิด



เชื่อ AI หันที

โค้ด/ผลอาจผิด รัน cell แล้ว "ตรวจ output" เสมอ



ทับไฟล์ดิบ

เก็บ raw แยกไว้เสมอ พังแล้วย้อนได้



ลบสิ่งที่ไม่เข้าใจ

คอลัมน์งง ๆ สืบก่อน อย่าลบทิ้งมั่ว

ถึงตาคุณแล้ว: ทำ notebook ให้ครบ

เป้าหมายในคาบ

- 1 สร้าง cleaning.ipynb ล้าง diabetes.csv ให้ครบ 6 ขั้น (cell + ตรวจสอบ ทุกขั้น)
- 2 ใส่ markdown อธิบายการตัดสินใจแต่ละขั้น
- 3 เซฟ diabetes_clean.csv แยกใน data/clean/
- 4 commit เป็นระยะ แล้ว push ขึ้น GitHub พร้อม README
- 5 โบนัส: ลองเอาข้อมูลสุขภาพจากงานตัวเองมาล้างด้วยวิธีเดียวกัน



ติดตรงไหน: ให้ AI เขียน/อธิบาย cell ได้เลย แต่ต้อง "รันแล้วตรวจสอบ output" ทุกครั้งก่อนไปต่อ

> recap

สรุป: วันนี้เราทำอะไรไปบ้าง



ล้างข้อมูลสุขภาพจริงครบ 6 ชั้น

สำรวจ → ลบซ้ำ → แปลง 0 → outlier → ค่าหาย → validate



ได้ผลงานชิ้นแรก

notebook + clean.csv + README + GitHub repo



ใช้ mindset เดิม

AI เขียน cell เราอ่านเข้าใจ + ตรวจ output



เข้า Portfolio ได้ทันที

ลิงก์ GitHub เดียว เปิดดู notebook ได้เลย



PROJECT 1 • DONE

ผลงานชิ้นแรก เสร็จแล้ว!

การบ้าน: ทำ README ให้สวย + commit/push ให้ครบ • เตรียม dataset ที่อยากใช้ใน Project ถัดไป

ต่อไป Project 2: SQL Analysis (ดึง + วิเคราะห์จากฐานข้อมูล)